



Authenticity Score Generator

Análisis de Costos de Infraestructura

14 de May de 2026

Documento preparado
para
análisis de caso de
negocio

1. Resumen Ejecutivo

Este documento proyecta los costos variables de infraestructura cloud para la solución ASG, con foco en el componente de inteligencia artificial que representa el ítem de mayor peso. El análisis compara distintos modelos de visión disponibles y proyecta el costo mensual en función del volumen de sesiones de scoring generadas.

~\$0.008 Costo variable por sesión (recomendado)	8 llamadas al modelo de visión por sesión	~\$80 Costo AI a 10.000 sesiones/mes	>95% Margen infraestructura vs. precio sugerido \$1+
---	--	---	--

2. Arquitectura Propuesta

La solución se apoya en servicios serverless de AWS, lo que elimina costos fijos de infraestructura. Solo se paga por uso efectivo.

Servicio	Rol en la arquitectura	Modelo de costo
API Gateway	Punto de entrada para todos los endpoints	Por request
Lambda	Endpoints sync: create_session, get_upload_url, confirm_upload, scoring_status	Por ejecución + duración
SQS	Buffer entre /generate_scoring/ y Step Functions	Por mensaje
Step Functions	Orquestación del flujo de scoring async (Map State para procesar N imágenes en paralelo)	Por transición de estado
Bedrock / Gemini	Modelos de visión para scoring por imagen y análisis de coherencia global	Por token (input/output)
S3	Almacenamiento de imágenes originales	Por GB almacenado + requests
DynamoDB	Estado de sesiones, imágenes y resultados	

3. Modelo de Consumo por Sesión de Scoring

Cada sesión de scoring implica analizar hasta 7 fotos de distintas partes del producto, más un análisis final de coherencia global. El código actual redimensiona las imágenes a 800px antes de enviarlas al modelo, lo cual es una optimización de costo importante que se mantiene en la arquitectura propuesta.

Calls al modelo por sesión:

Tipo de análisis	Cant.	Input tokens	Output tokens	Notas
Análisis por imagen (criterios individuales)	7	~1.000 (800 img + 200 prompt)	~150 (JSON score)	Claude Haiku recomendado
Análisis de coherencia global	1	~500 (texto con resultados)	~300 (evaluación global)	Claude Sonnet recomendado
TOTAL POR SESIÓN	8	~7.500 tokens	~1.350 tokens	

** El análisis de coherencia global recibe solo los resultados en texto (scores + observaciones de cada imagen), no las imágenes originales. Esto reduce el costo de ese paso en ~90% respecto a reenviar todas las fotos.*

4. Comparativa de Modelos de IA

La elección del modelo de visión es la palanca de costo más importante de toda la arquitectura. La tabla compara las opciones más relevantes:

Modelo	Input \$/M tokens	Output \$/M tokens	Costo por sesión	Calidad vision	Latencia
Gemini 2.0 Flash	\$0.10	\$0.40	~\$0.001	Alta	Baja
Claude Haiku 3.5 (Bedrock)	\$0.80	\$4.00	~\$0.005	Muy alta	Baja
Gemini 1.5 Pro	\$1.25	\$5.00	~\$0.012	Muy alta	Media
Claude Sonnet 3.5 (Bedrock)	\$3.00	\$15.00	~\$0.025	Excelente	Media

Estrategia Recomendada

Usar **Claude Haiku** para los 7 análisis por imagen (velocidad + costo) y **Claude Sonnet** para el análisis de coherencia global (1 sola llamada, mayor razonamiento). Esto da el mejor balance calidad/costo: ~\$0.008 por sesión.

5. Proyección de Costos Mensuales

La siguiente tabla proyecta el costo total de infraestructura por nivel de volumen mensual de sesiones de scoring procesadas:

Sesiones/mes	AI (Haiku+Sonnet)	Step Functions	Lambda+DynDB+S3	Total Infraestr.	Costo/sesión
1.000	\$8	\$1	\$2	\$11	\$0.011
5.000	\$40	\$3	\$8	\$51	\$0.010
10.000	\$80	\$6	\$15	\$101	\$0.010
25.000	\$200	\$16	\$35	\$251	\$0.010
50.000	\$400	\$31	\$65	\$496	\$0.010
100.000	\$800	\$63	\$125	\$988	\$0.010

* El costo por sesión se mantiene estable (~\$0.010) gracias al modelo de precios pay-per-use de todos los servicios involucrados. No hay costos fijos de infraestructura.

6. Análisis de Margen sobre Precio de Venta

Considerando distintos escenarios de precio de venta por sesión de scoring a plataformas B2B clientes:

Precio de venta por sesión	Costo infraestr. por sesión	Margen bruto por sesión	Margen %	Break-even (sesiones/mes)
\$0.25	\$0.010	\$0.240	96%	—
\$0.50	\$0.010	\$0.490	98%	—
\$1.00	\$0.010	\$0.990	99%	—
\$2.00	\$0.010	\$1.990	99.5%	—

El costo de infraestructura representa menos del 2% del precio de venta en cualquier escenario razonable. El margen bruto del negocio estará determinado principalmente por costos de desarrollo, go-to-market y soporte, no por infraestructura.

7. Riesgos de Costo y Mitigaciones

Riesgo	Impacto	Mitigación
Imágenes en alta resolución sin redimensionar	Costo de tokens 3x-10x más alto	Resize a 800px antes de enviar al modelo (ya implementado en el prototipo)
Spike inesperado de volumen	Factura mensual elevada	Throttling por consumer_platform_id en API Gateway + alertas en CloudWatch
Dependencia de proveedor (solo Gemini o solo Bedrock)	Riesgo de disponibilidad y cambios de precio	Abstraer el modelo detrás de una interfaz (el analyzer.py actual ya tiene este patrón)
Sesiones de scoring incompletas (usuario no llama /generate_scoring/)	Imágenes huérfanas generando costo en S3	TTL en DynamoDB + lifecycle policy en S3 para eliminar imágenes sin scoring tras 7 días

8. Conclusión

El modelo de costos de infraestructura de ASG es altamente favorable para un negocio B2B. Los puntos clave a retener para el caso de negocio son:

01	Costo variable de ~\$0.010 por sesión de scoring, independiente del volumen.
02	Sin costos fijos de infraestructura: arquitectura 100% serverless (AWS Lambda, Step Functions, S3, DynamoDB).
03	El componente de mayor costo es el modelo de IA (~80% del total), con opciones de optimización claras según calidad requerida.
04	Margen bruto sobre infraestructura superior al 96% en cualquier escenario de precio de venta razonable.
05	La arquitectura escala desde 1.000 a 100.000+ sesiones/mes sin cambios estructurales ni inversión adicional.